

基于 Agent 轨迹的检索器训练

官方 LRAT Training pairs 的训练与验证

DefaultGroup | 中国人民大学 CCIR 参赛队

中国人民大学高瓴人工智能学院



中國人民大學
RENMIN UNIVERSITY OF CHINA

团队与分工

我们分别负责数据核验、数据切分、模型训练、榜单评测和复现交付。

01 刘琦 (队长)

13798122637

技术分工：整体方案设计与答辩协作；

02 赵梓名

18875820386

技术分工：训练、评测与交付协作；

队伍信息 Team ID: 362259 Record ID: 998912

1. 研究背景：检索器的服务对象从人转向 Agent

当检索器的服务对象从人转向 Agent，检索结果的消费方式与训练监督来源也随之变化^[1]。



[1] Yuqi Zhou et al., *Learning to Retrieve from Agent Trajectories*, SIGIR 2026.

如何利用 Agent Trajectory 训练面向 Agentic Search 的 retriever?

2. 从 LRAT 论文到本次训练：三个具体问题

赛题提供 Training pairs、Agent trajectories 和 Corpus，并指定 Qwen3-Embedding-0.6B 作为基础模型。
在不重新生成 trajectory 的前提下，如何可靠地利用已有 Training pairs 完成训练？

01

每条 pair 能否回到轨迹？

核对 query、正例、负例和样本权重与 Search / Browse / reasoning 的映射，并确认文档均在 Corpus 中。

02

相同 query 如何避免跨集合？

同一 normalized query 可能对应多条 source rows，随机切分会让相同 query 同时出现在 train 和 dev。

03

训练轮数和学习率怎样选择？

完整训练成本较高，因此先固定样本组装和损失，再分别用 A 榜和 dev1500 选择 epoch 与 LR。

针对这三个问题，我们最终采用四个步骤：



3.1 LRAT 训练信号与来源核验

LRAT 用 Browse 区分候选正负：已 Browse 文档作候选正例，未 Browse 候选入负例池。

LRAT 论文中的训练信号形成




核验结果

96,504 pairs; 96,366 条唯一映射; 138 条多候选、字段一致; 0 条无法匹配。
1,989,015 个文档引用全部命中固定 LRAT Corpus; 无缺失或文本不一致。

3.2 训练数据切分：按 normalized query 整组隔离

一条 query 可能对应多条 Training pair；这些 rows 先按 normalized query 归并为 query group。




三组间的 overlap = 0。

query group 只用于数据切分；同一 normalized query 的 Training pair rows 必须进入同一个集合。
它不等于于训练时的 candidate group。

3.3 训练候选组装：1 个正例 + 5 个随机负例

每行的负例并非单个文档，而是一个候选池；为统一每次训练的候选规模，我们采用以下三步组装流程：



3.4 加权对比训练：使用 reweight_rate 调整样本贡献



两张 A40 各处理 1 个 candidate group, gather 后另一 query 的候选文档作为 in-batch negatives
我们先计算每个 query 的对比交叉熵, 随后按对应 Training pair 的 reweight_rate 加权。

目标函数

$$s(q, d) = \frac{q^\top d}{\tau}, \quad \tau = 0.02$$

$$\mathcal{L} = \frac{\sum_j w_j \ell_j}{\sum_j w_j}$$

ℓ_j : query j 对比交叉熵;

w_j : Training pair 的 reweight_rate。

权重在每个 2-query micro-batch 内归一化。

批次组织

硬件	2 × A40
micro-batch	2 groups
梯度累积	4 micro-steps
optimizer update	per 8 candidate groups

3.5 训练配置选择：先确定训练轮数，再选择学习率

训练轮数

我们固定 $LR=10^{-6}$ ，使用完整 96,504 条 Training pairs，分别训练 1、2、3 epoch 并提交模型至 A 榜，结果如下：

epoch	Total	Recall	Success	Avg_Steps
1	40.1	44.8	21.0	15.4
2	38.2	42.7	18.3	15.5
3	38.7	43.4	19.0	15.8

完整 pairs 上的实验确定使用 1 epoch；随后在 query-disjoint 训练阶段选择学习率。

学习率 (LR)

固定 query-disjoint train (94,113 rows)，四个 LR 各训练 500 个 optimizer steps，随后在 dev1500 上比较 R@1 与 MRR：

学习率	R@1	MRR
3×10^{-7}	0.4913	0.6419
5×10^{-7}	0.5073	0.6571
1×10^{-6}	0.5433	0.6831
2×10^{-6}	0.5640	0.6993

R@1 和 MRR 同时在 $LR=2 \times 10^{-6}$ 时最高，因此选择该学习率。

最终采用：1 epoch + $LR=2 \times 10^{-6}$ 。

4.1 A 榜结果：整体方案与内部学习率对照

配置	Total ↑	Recall ↑	Success ↑	Avg_Steps ↓
Baseline Qwen3 Embedding	28.5	28.5	10.6	17.8
Baseline LRAT: 2 epochs, LR = 1e-6	34.0	36.1	15.5	16.8
Query-disjoint: 1 epochs, LR = 1e-6	39.5	45.0	19.8	15.9
Query-disjoint: 1 epochs, LR = 2e-6	40.6	46.3	21.1	16.0

Total: 综合得分; Recall: 检索器召回率; Success: 端到端成功率; Avg_Steps: 平均执行轮次。


平台结果

Baseline Qwen3: 28.5 → 40.6 (+12.1)。
Baseline LRAT: 34.0 → 40.6 (+6.6)。

内部学习率调整

在同一 query-disjoint 设置下，将 LR 从 10^{-6} 调至 2×10^{-6} ，Total 从 39.5 提升至 40.6。

4.2 B 榜结果：复现验收与三种 Agent 的实测结果



复现验收

- 固定模型、代码和关键配置的身份；
- 用新 CPU 进程独立加载最终模型；
- 回读 Hugging Face revision 并核对文件哈希；
- GitHub repository 与本地文件校验。

B 榜结果

- DeepSeek-V4-Flash-0731: Total 67.42;
- Qwen3.5-35B-A3B: Total 60.96;
- gpt-oss-120b: Total 40.16;
- 平均 Total 56.18, 最高与最低相差 27.26。

注：未提供逐 Agent baseline，因此本页只报告三种 Agent 的绝对表现，不作相对提升判断。

5. 总结：我们做了什么，结果说明什么

01

数据链路

- 从 Training pairs 追溯核验到 trajectory / Corpus
- normalized query 按 group 完成整组隔离

02

结果

- A 榜最终 Total 为 40.6
- 相比 Baseline LRAT 34.0, 提高 6.6
- B 榜三 Agent 平均: 56.18

03

关键发现

- 同一 query-disjoint 设置调整 LR: 39.5 $\rightarrow$ 40.6
- 三个 Agent Total 相差 27.26, 同一 retriever 的绝对表现对具体 Agent 仍然敏感